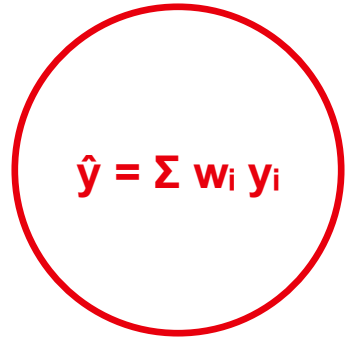
ANÁLISIS Y CIENCIA DE DATOS · PROYECTO FINAL

Todo modelo es un voto ponderado

Pesos, evidencia y geometría de cinco modelos sobre la demanda de bicicletas de Washington D.C. (2011)

Rodolfo Flores · Nohel Estrada · Humberto Najar
Facultad de Ingeniería, Universidad del Istmo de Guatemala
6 de noviembre de 2026



Una predicción es un voto de las filas de entrenamiento

$$\hat{y}(x) = \Sigma_i \, w_i(x) \cdot y_i$$

01

¿Quién vota?

Todas las filas (OLS, ridge), k vecinos, una hoja del árbol o la unión de hojas del bosque.

02

¿Cuánto vale cada voto?

1/k, 1/|hoja|, o un peso que depende de la geometría de X. El parecido entre filas es el kernel.

03

¿Hay votos en contra?

OLS y ridge dan pesos negativos; k-NN, árbol y bosque son promedios convexos ($w \geq 0$, $\Sigma w = 1$).

PLAN: PESOS → EVIDENCIA → COSTO DE LA FLEXIBILIDAD → ESCALA → VEREDICTO

Dos conjuntos de datos, una sola receta de preparación

PARTE 1 · CALIFORNIA HOUSING

- 20 640 distritos censales de 1990, 8 variables
- y = valor mediano de la vivienda (cientos de miles de USD)
- 16 512 entrenamiento · 4 128 prueba

PARTES 2–5 · BIKESHARE D.C.

- 8 645 horas de 2011; y = log(1 + bikers)
- day, hr, weekday, workingday, holiday, temp, hum, windspeed, mes 1–12, weathersit 1–4
- 6 916 entrenamiento · 1 729 prueba

100 %

de las filas cumplen casual + registered = bikers: usarlas sería usar la respuesta (fuga).

105

desviación cruda de day; hr ≈ 6.9, mes ≈ 3.4, windspeed ≈ 0.12. La usamos en la Parte 4.

80 / 20

partición con random_state = 0; el escalador se ajusta solo con entrenamiento.

OLS: del estimador al voto

01 Mínimos cuadrados con la matriz de diseño $\tilde{X} = [1, X]$

$$\hat{\beta} = (\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top \mathbf{y}$$

02 La predicción es lineal en y: lo que multiplica a y es el vector de pesos

$$\hat{y}(x) = \tilde{x}^\top \hat{\beta} = \tilde{x}^\top (\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top \mathbf{y} \;\Rightarrow\; w(x)^\top = \tilde{x}^\top (\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top$$

03 La columna de unos es la primera columna de $\tilde{X}$ ($1 = \tilde{X}e_1$), así que los pesos suman 1

$$\mathbf{1} = \tilde{X} e_1 \;\Rightarrow\; w(x)^\top \mathbf{1} = \tilde{x}^\top (\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top \tilde{X} e_1 = \tilde{x}^\top e_1 = 1$$

04 Equivalente: H proyecta sobre el espacio columna de $\tilde{X}$ y el vector de unos ya vive ahí

$$H\mathbf{1} = \tilde{X}(\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top \tilde{X} e_1 = \tilde{X} e_1 = \mathbf{1}$$

Los pesos de OLS suman 1 para cualquier x, pero pueden ser negativos: no es un promedio convexo.

Ridge: el intercepto no se penaliza

01 Problema que resuelve Ridge de scikit-learn (λ no toca a β_0)

$$\min_{\beta_0,\,\beta} \|\mathbf{y} - \beta_0\mathbf{1} - X\beta\|^2 + \lambda\|\beta\|^2$$

02 Derivar respecto a β_0 despeja el intercepto; queda un ridge sobre los datos centrados

$$\partial/\partial\beta_0 = 0 \;\Rightarrow\; \hat{\beta}_0 = \bar{y} - \bar{x}^\top\hat{\beta} \;\Rightarrow\; \hat{\beta} = (X_c^\top X_c + \lambda I)^{-1} X_c^\top \mathbf{y}$$

03 Sustituir en $\hat{y}(x) = \hat{\beta}_0 + x^\top\hat{\beta}$ y leer los pesos

$$\hat{y}(x) = \bar{y} + (x - \bar{x})^\top\hat{\beta} = \left[\tfrac{1}{n}\mathbf{1}^\top + (x - \bar{x})^\top (X_c^\top X_c + \lambda I)^{-1} X_c^\top\right]\mathbf{y}$$

04 Suma de pesos: el segundo término se anula porque las columnas centradas suman cero

$$\sum_i w_i(x) = 1 + (x - \bar{x})^\top (X_c^\top X_c + \lambda I)^{-1} X_c^\top \mathbf{1} = 1 \qquad (X_c^\top \mathbf{1} = 0)$$

05 Lo “obvio” (penalizar también la columna de unos) no cuadra con .predict()

$$\text{unos penalizados}: \quad \hat{\beta}_0 = \frac{n\,\bar{y}}{n + \lambda}, \qquad \sum_i w_i(x) = \frac{n}{n+\lambda} = \frac{16\,512}{16\,612} = 0.994$$

k-NN, árbol y bosque: promedios locales

01 k-NN (k = 30): 1/k a cada uno de los k vecinos (.kneighbors())

$$w_i(x) = \frac{1}{k}\mathbf{1}\{x_i \in N_k(x)\}$$

02 Árbol (profundidad 6): 1/|hoja| a quien cae en la misma hoja (.apply())

$$w_i(x) = \frac{\mathbf{1}\{x_i \in L(x)\}}{|L(x)|}$$

03 Bosque sin bootstrap: cada árbol promedia su hoja y el bosque promedia los T árboles

$$w_i(x) = \frac{1}{T}\sum_{t=1}^{T}\frac{\mathbf{1}\{x_i \in L_t(x)\}}{|L_t(x)|}$$

Los tres pesos son ≥ 0 y suman 1: un promedio convexo de las y de entrenamiento.

Bosque con bootstrap y proximidad

04 Con bootstrap cada hoja promedia su muestra: la fila i cuenta c_{it} veces (las veces que entró al árbol t)

$$w_i(x) = \frac{1}{T}\sum_{t=1}^{T}\frac{c_{it}\,\mathbf{1}\{x_i \in L_t(x)\}}{\sum_j c_{jt}\,\mathbf{1}\{x_j \in L_t(x)\}}$$

05 Proximidad: cuenta coincidencias sin dividir entre el tamaño de la hoja; su suma es el tamaño medio de la hoja

$$\text{prox}_i(x) = \frac{1}{T}\sum_t \mathbf{1}\{x_i \in L_t(x)\}, \qquad \sum_i \text{prox}_i(x) = \frac{1}{T}\sum_t |L_t(x)|$$

Fila 7: Σ prox = 6.495 = tamaño medio de la hoja; normalizarla al final no basta (difiere hasta 0.0026).

Los pesos de cinco modelos, en una tabla

Modelo	Peso $w_i(x)$	¿Por qué suman 1?
OLS	$\tilde{x}^T (\tilde{X}^T\tilde{X})^{-1} \tilde{X}^T$	$H \cdot 1 = 1$: el vector de unos está en el espacio columna
Ridge ($\lambda = 100$)	$1/n + (x - \bar{x})^T (X_c^T X_c + \lambda I)^{-1} X_c^T$	$X_c^T 1 = 0$; el intercepto no se penaliza
k-NN ($k = 30$)	$1/k$ si x_i es vecino de x	k vecinos × 1/k
Árbol (prof. 6)	$1\{\text{misma hoja}\} / \lvert\text{hoja}\rvert$	promedio de la hoja
Bosque (200 árboles)	$(1/T)\ \Sigma_t\ 1\{\text{misma hoja en } t\} / \lvert\text{hoja}_t\rvert$	promedio de promedios

RIDGE "OBVIO": PENALIZAR TAMBIÉN LA COLUMNA DE UNOS

No cuadra con .predict() (diferencia de hasta 0.012) y los pesos suman **$n/(n+\lambda) = 0.994$**: el intercepto se encoge hacia 0.

Los cinco votos reproducen .predict() a 10^{-14}

Fila de prueba 7	Predicción	Σ w	Pesos ≠ 0	Pesos < 0
OLS	3.057	1.000	16 512	**4 144**
Ridge	3.056	1.000	16 512	**4 130**
k-NN	3.208	1.000	30	0
Árbol	3.699	1.000	328	0
Bosque	3.718	1.000	388	0

100 / 100

verificaciones: 20 filas de prueba × 5 modelos, $|\Sigma\, w_i y_i - \text{pred}| < 10^{-8}$

≈ 4 000

filas votan en contra en OLS y ridge: una de cada cuatro

Con bootstrap la fórmula falla; la proximidad no es un peso

0.044

error máximo de la fórmula con bootstrap = True (contra 10^{-15} sin bootstrap)

36.8 %

de las filas queda fuera de la bolsa de cada árbol; otras entran 2, 3… veces

6.495

suma de la proximidad de la fila 7 = tamaño medio de su hoja en los 200 árboles

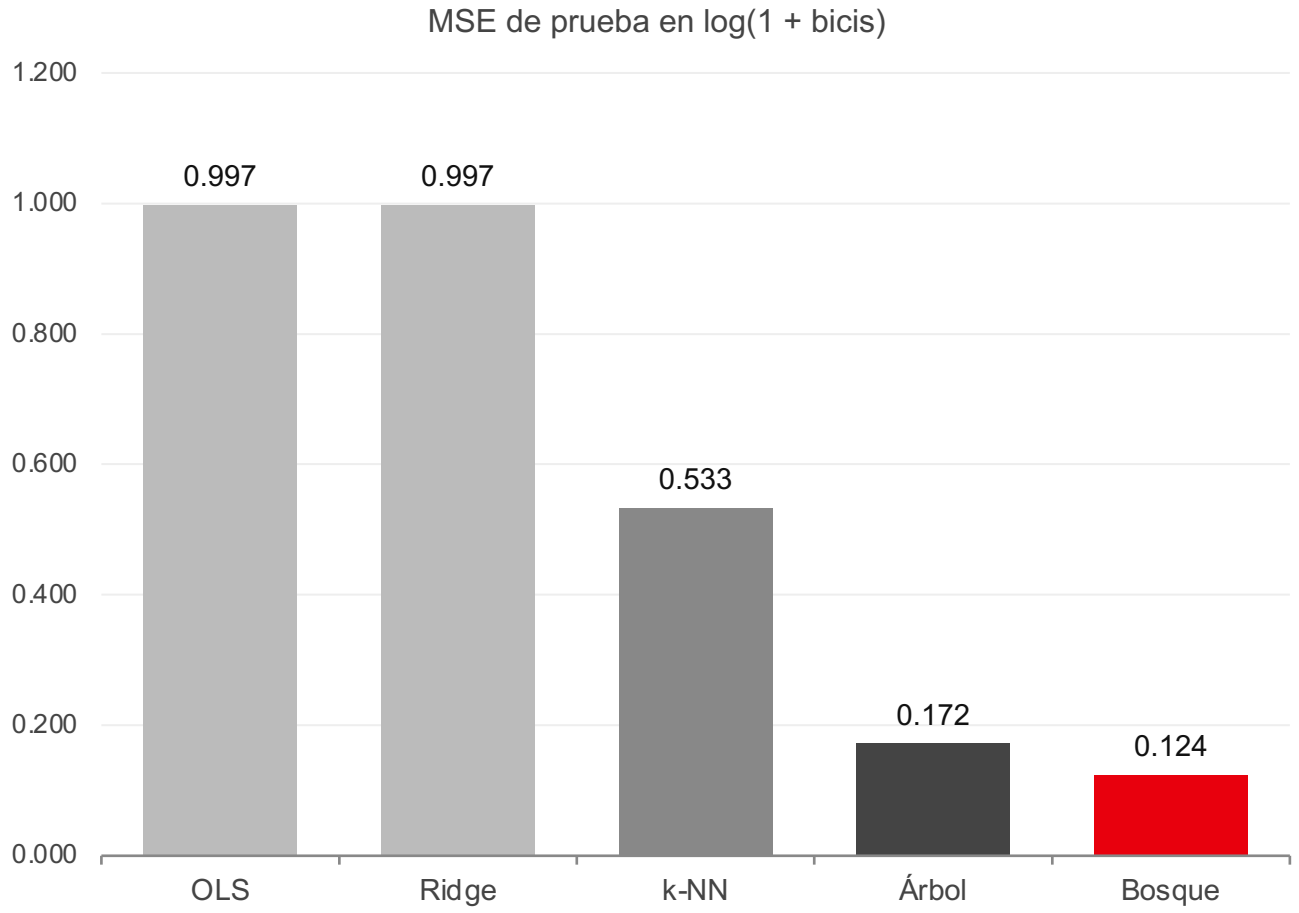
ARREGLO PARA BOOTSTRAP

- Contar cada fila tantas veces como entró a su árbol (c_{it}):
- $w_i(x) = (1/T)\ \Sigma_t\ c_{it}\ 1\{\text{misma hoja}\} / \Sigma_j\ c_{jt}\ 1\{\text{misma hoja}\}$
- Vuelve a reproducir .predict() a 10^{-15}

¿QUÉ LE FALTA A LA PROXIMIDAD?

- Cada coincidencia vale 1, sin importar el tamaño de la hoja
- Hay que dividir entre $|L_t(x)|$ dentro de cada árbol, antes de promediar
- Normalizarla al final no basta (difiere hasta 0.0026)

El bosque gana; los lineales no dibujan la hora punta



Modelo	Elegido por CV	MAE (bicis)
OLS	—	84.6
Ridge	$\lambda \approx 17.8$	84.5
k-NN	k = 4	53.1
Árbol	profundidad 11	27.4
Bosque	**min_samples_leaf = 1**	**27.2**

IMPORTANCIA EN EL BOSQUE

hr 0.65 · temp 0.09 · hum 0.07 · day 0.07

Dos números para la ficha de evidencia (y un tercero)

01 Tamaño efectivo de muestra de Kish: en cuántas filas se apoya la predicción (m pesos iguales ⇒ m)

$$N_{\text{ef}}(x) = \frac{\left(\sum_i w_i(x)\right)^2}{\sum_i w_i(x)^2}$$

02 Concentración: la condición de Hájek–Šidák del TLC; si es grande, una sola fila manda

$$c(x) = \frac{\max_i \, w_i(x)^2}{\sum_j w_j(x)^2}$$

03 Lo que agregamos: la dispersión ponderada de los testigos y la varianza aproximada del voto

$$\hat{\sigma}(x) = \sqrt{\sum_i w_i(x)\, y_i^2 - \hat{y}(x)^2}, \qquad \operatorname{Var}[\hat{y}(x)] \approx \frac{\sigma^2(x)}{N_{\text{ef}}(x)}$$

Hiperparámetros por CV de 5 pliegues: ridge λ ≈ 17.8, k = 4, profundidad 11, min_samples_leaf = 1.

Tres consultas: una de ellas descansa en una sola fila

N_EF MEDIANO

Vie 7 oct · 11 h

Real	**230**
Predicción bosque	**187**
N_ef	**8.75**
c(x)	**0.42**

Testigo principal: 10 h de la misma semana (w = 0.22)

N_EF MÍNIMO

Sáb 29 oct · 18 h · nieve

Real	**43**
Predicción bosque	**32**
N_ef	**1.04**
c(x)	**0.9998**

Testigo principal: 17 h del mismo día (w = 0.98)

MAYOR ERROR

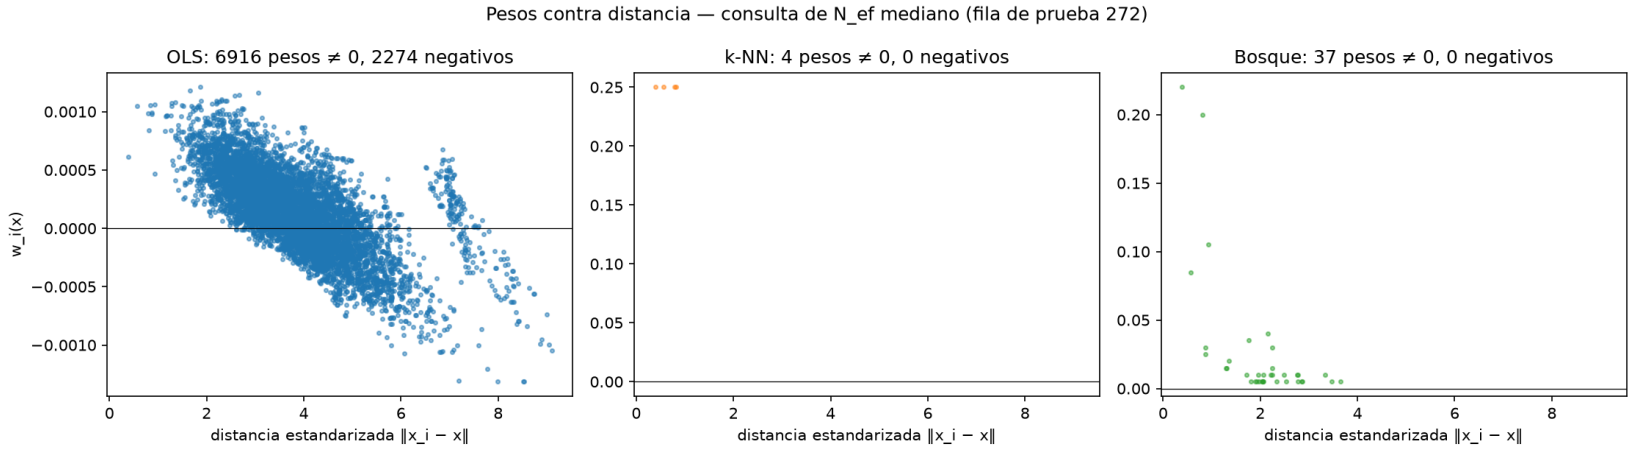
Mar 18 ene · 12 h

Real	**3**
Predicción bosque	**29**
N_ef	**2.26**
c(x)	**0.98**

Testigo principal: 13 h del mismo día (w = 0.66)

OLS/ridge: N_ef ≈ 1 000, pero sus testigos de mayor |w| son tardes lluviosas de verano con peso negativo.

OLS vota en contra con las filas más lejanas



2 274

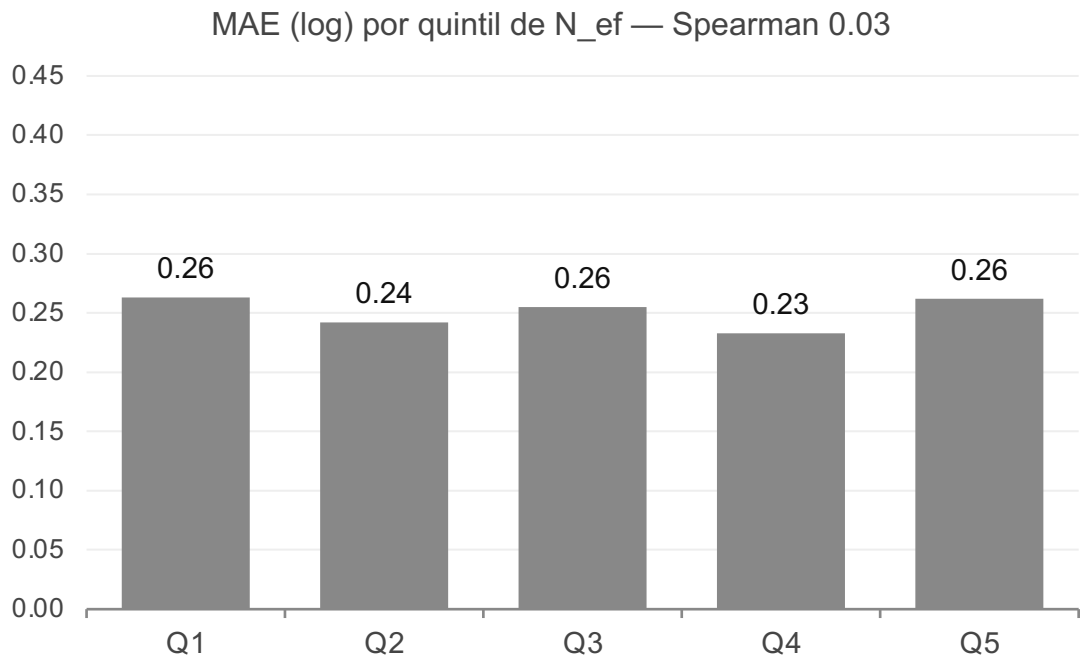
a 3 115 de los 6 916 pesos OLS son negativos, según la consulta

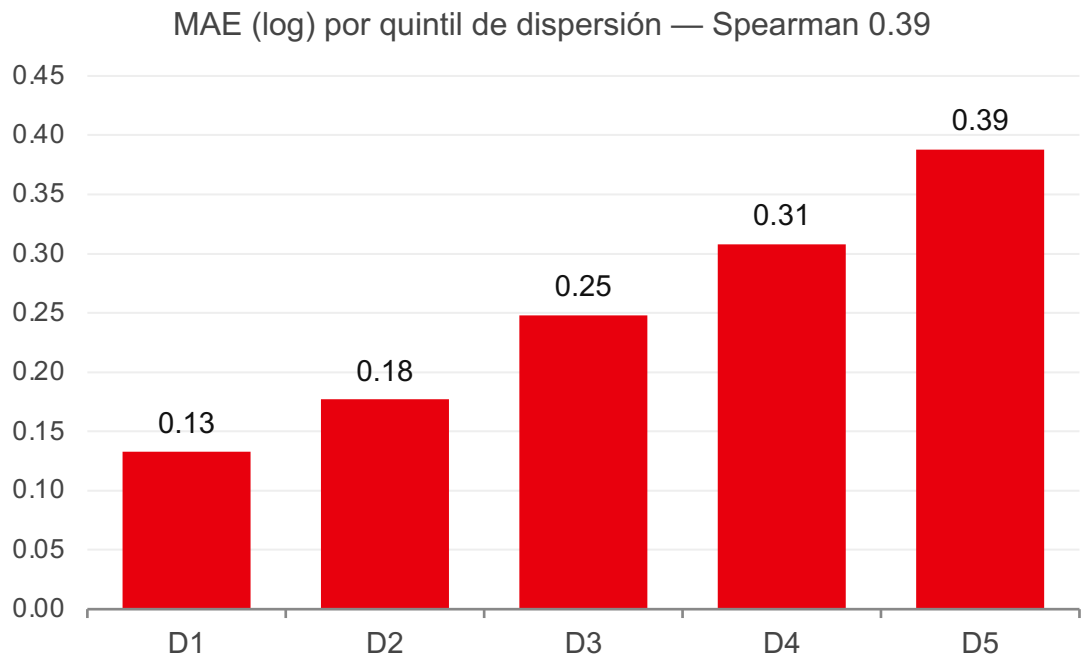
p96 – p99

percentil de distancia de las 5 filas con peso más negativo

- Cerca: pesos positivos. Lejos: negativos. Los de mayor magnitud están en los extremos de la nube.
- Como w(x) es lineal en x, OLS usa puntos de palanca (viento ≈ 0.85, lluvia) para inclinar el hiperplano y extrapolar.
- k-NN (4 pesos) y el bosque (37) solo dejan votar a vecinos cercanos, siempre con peso positivo.

N_ef no predice el error; la dispersión de testigos sí





Por qué: el bosque corta fino donde la señal cambia rápido (mediodía: N_ef ≈ 5, error bajo) y en log domina el ruido de madrugada (1–5 h: N_ef alto, error 0.33–0.48). Var ≈ $\sigma^2(x)/N_{ef}$: hace falta $\sigma^2(x)$.

Cuándo decirle a alguien que no confíe en una predicción

01

Los testigos discrepan

Dispersión ponderada alta: el error se triplica entre el quintil más bajo y el más alto.

02

Un solo testigo decide

N_ef ≲ 2 o c(x) > 0.9, y ese testigo no se parece a la consulta (otra hora, otra estación).

03

OLS extrapola

Los testigos de mayor |w| son filas lejanas con peso negativo: no es un promedio de casos parecidos.

04

Los modelos discrepan

El 18 de enero los cinco modelos van de 23 a 58 bicis: no hay casos parecidos cerca.

Trazas de OLS y ridge

OLS Traza cíclica: tr(AB) = tr(BA)

$$\operatorname{tr}(H) = \operatorname{tr}\left((\tilde{X}^\top \tilde{X})^{-1} \tilde{X}^\top \tilde{X}\right) = \operatorname{tr}(I_{p+1}) = p + 1$$

RID SVD de la matriz centrada; el término $(1/n)11^\top$ aporta traza 1

$$X_c = UDV^\top : \quad X_c(X_c^\top X_c + \lambda I)^{-1} X_c^\top = UD(D^2 + \lambda I)^{-1} DU^\top \;\Rightarrow\; \operatorname{tr}(S) = 1 + \sum_j \frac{d_j^2}{d_j^2 + \lambda}$$

Con λ = 0 la traza de ridge es p + 1 = 11 (OLS); con λ → ∞ tiende a 1.

Trazas de k-NN, árbol y bosque

KNN Sin filas repetidas, cada fila es su propio vecino más cercano (distancia 0)

$$S_{ii} = w_i(x_i) = \frac{1}{k} \quad (x_i \in N_k(x_i)) \;\Rightarrow\; \operatorname{tr}(S) = \frac{n}{k}$$

ÁRB Agrupar la suma por hojas: cada hoja aporta |L| · 1/|L| = 1

$$\operatorname{tr}(S) = \sum_i \frac{1}{|L(x_i)|} = \sum_L \sum_{i \in L} \frac{1}{|L|} = \sum_L 1 = \#\,\text{hojas}$$

BOS Sin forma cerrada: se suma S_{ii} directamente (sin bootstrap = nº medio de hojas)

$$\operatorname{tr}(S) = \frac{1}{T} \sum_{t=1}^{T} \sum_{i=1}^{n} \frac{1}{|L_t(x_i)|}$$

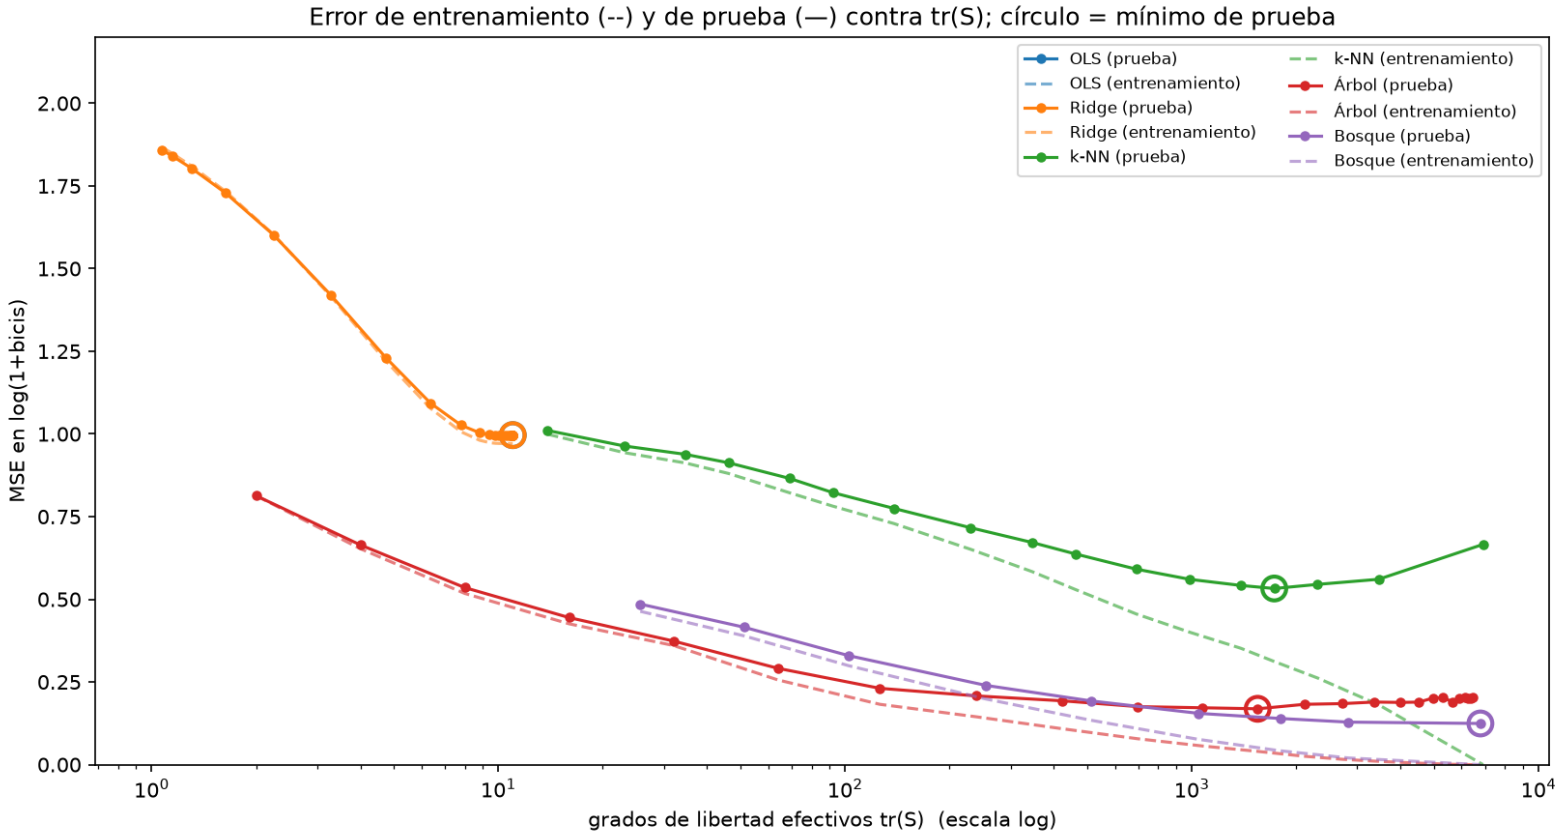
tr(S): fórmula contra np.trace(S)

Modelo	Fórmula	Idea
OLS	$p + 1$	$\mathrm{tr}(\tilde{X}(\tilde{X}^T\tilde{X})^{-1}\tilde{X}^T) = \mathrm{tr}(I_{p+1})$
Ridge	$1 + \Sigma\, d_j^2/(d_j^2 + \lambda)$	SVD $X_c = UDV^T$
k-NN	n / k	$S_{ii} = 1/k$ (sin filas repetidas)
Árbol	nº de hojas	$\Sigma_L \Sigma_{\{i \in L\}} 1/\lvert L\rvert = \Sigma_L 1$
Bosque	$\Sigma\, S_{ii}$	sin forma cerrada

n = 2 000	Fórmula	np.trace(S)
OLS	11	11.000
Ridge λ = 17.8	10.197	10.197
k-NN k = 4	500	500.000
Árbol prof. 11	701	701.000
Bosque	1 967.56	1 967.56

MAX |S·Y − PRED| ≈ 10^{-15}

El bosque casi interpola y aun así generaliza mejor



MÍNIMO DEL ERROR DE PRUEBA

Familia	Parámetro	MSE
OLS / Ridge	$\lambda \to 0$	0.997
k-NN	k = 4	0.533
Árbol	prof. 12	0.169
Bosque	**msl = 1**	**0.124**

tr(S) cuenta el voto de cada fila por sí misma; en un punto nuevo el bosque promedia 200 árboles distintos.

Optimismo: por qué cuesta 2σ²·tr(S)/n

01 Definición (ESL §7.4): error en los mismos x_i con y nuevas menos error de entrenamiento

$$\text{Optimismo} = E[\text{Err}_{\text{in}} - \overline{\text{err}}] = \frac{2}{n}\sum_{i=1}^{n}\text{Cov}(\hat{y}_i, y_i)$$

02 Con y nueva independiente de ŷ: se expande alrededor de f_i y el término cruzado vale 0

$$E(y_i^{\text{nueva}} - \hat{y}_i)^2 = \sigma^2 + E(f_i - \hat{y}_i)^2$$

03 Con la misma y: el término cruzado es $-2\cdot\text{Cov}(\hat{y}_i, y_i)$; la resta da el resultado del paso 1

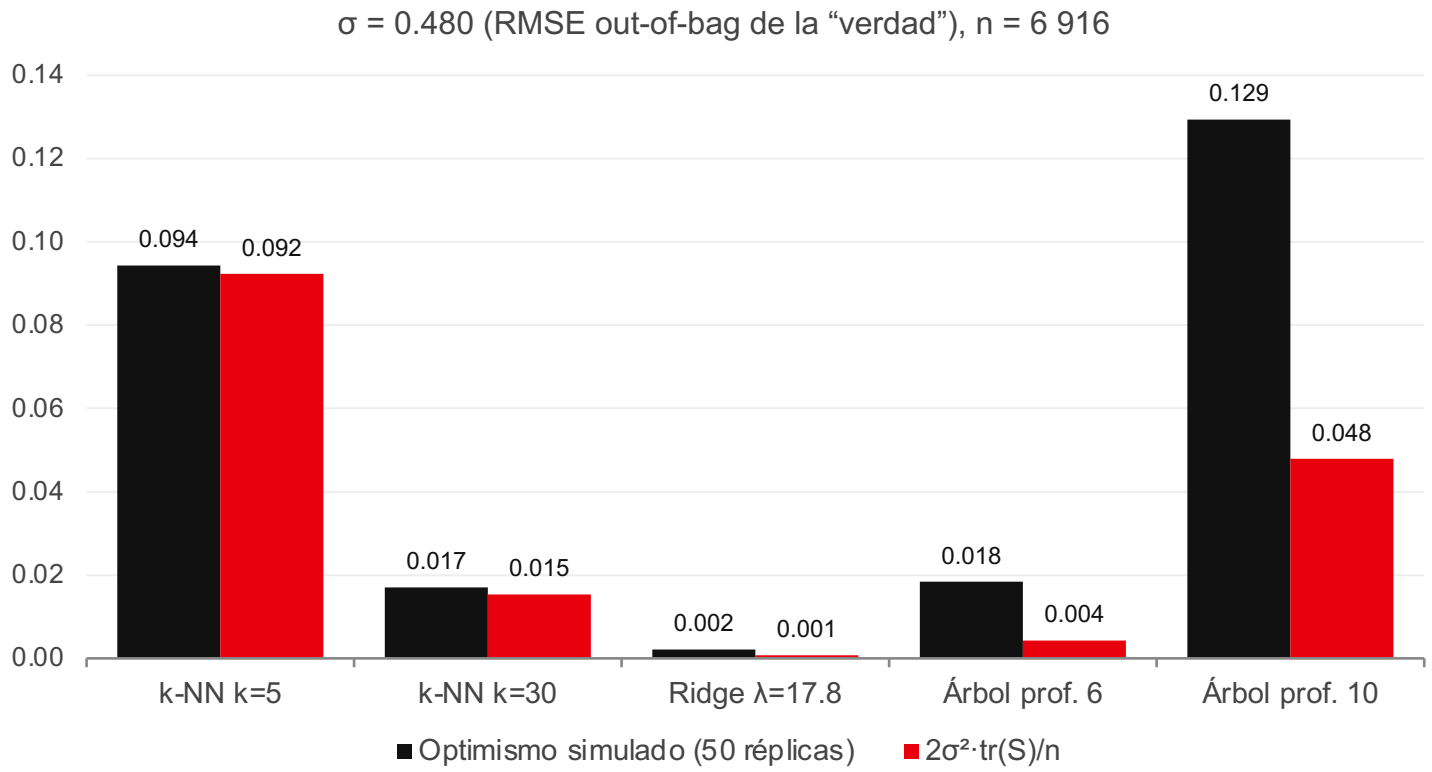
$$E(y_i - \hat{y}_i)^2 = \sigma^2 + E(f_i - \hat{y}_i)^2 - 2\,\text{Cov}(\hat{y}_i, y_i)$$

04 Si S no depende de y y $\text{Var}(y_i) = \sigma^2$ (independientes), solo sobrevive j = i

$$\text{Cov}(\hat{y}_i, y_i) = \sum_j S_{ij}\,\text{Cov}(y_j, y_i) = \sigma^2 S_{ii} \;\Rightarrow\; \text{Optimismo} = \frac{2\sigma^2\,\text{tr}(S)}{n}$$

En el árbol S depende de y (los cortes miran y): la fórmula subestima el optimismo 2.7× a 4.3×.

$2\sigma^2 \cdot tr(S)/n$ solo cuadra si S no depende de y



3.5: la brecha prueba − entrenamiento no es el optimismo, porque en prueba también cambian los x.

3.4 · POR QUÉ FALLA EN EL ÁRBOL

- k-NN y ridge: opt/fórmula = 1.02, 1.11 y ≈1 (dentro de 1.5 ee)
- Árbol: 4.3× y 2.7×. Los cortes se eligen mirando y, así que S depende de y

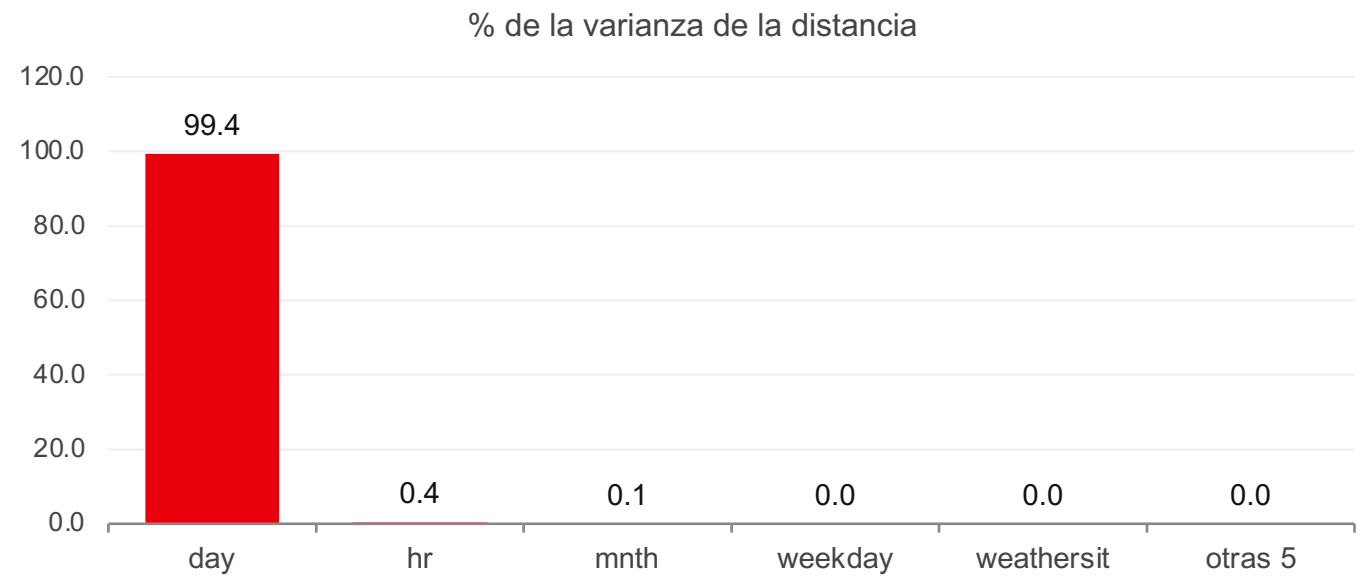
3.6 · OUT-OF-BAG

Error (MSE)	Valor
Entrenamiento	0.019
Out-of-bag	**0.141**
Prueba	0.136

Escoger la escala es escoger el kernel

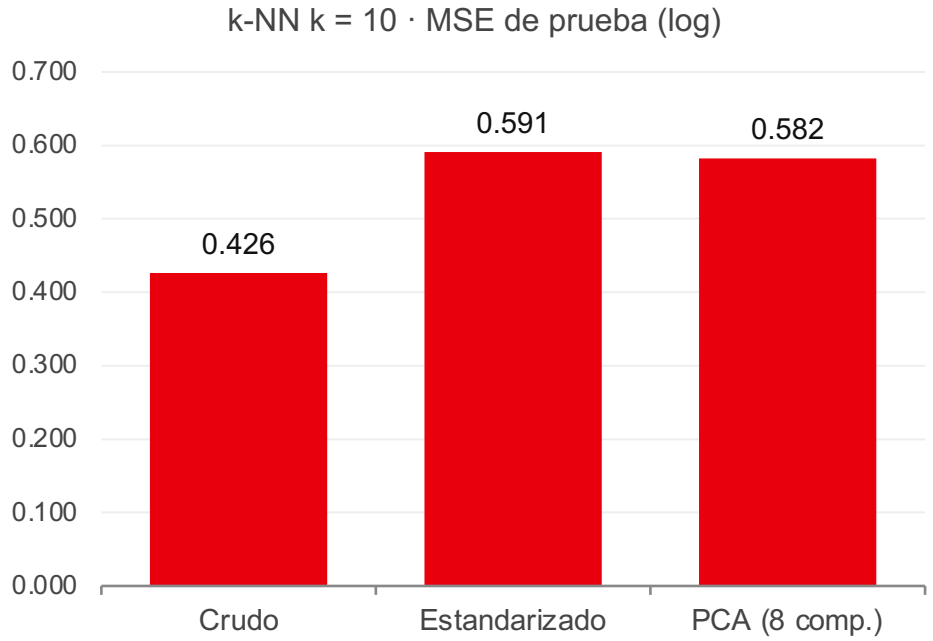
$$d^2(x, x') = \sum_j (x_j - x'_j)^2 \qquad \text{vs.} \qquad d^2_{\text{est}}(x, x') = \sum_j \frac{(x_j - x'_j)^2}{s_j^2}$$

APORTE ESPERADO A D^2 EN ESCALA CRUDA ($\propto$ VARIANZA)



- Desviaciones crudas (0.4): day ≈ 105, hr ≈ 6.9, mes ≈ 3.4, weekday ≈ 2.0, temp ≈ 0.20, windspeed ≈ 0.12
- Pero day y hr están en enteros: localmente, 1 día pesa igual que 1 hora → "misma hora en días vecinos"
- k-NN y k-means dependen de la distancia; el árbol no (solo usa el orden de cada variable)

En crudo, k-NN busca la misma hora en días vecinos



4.1 – 4.2 · K-NN

- day aporta 99.4 % de la varianza de la distancia cruda, pero day y hr están ambas en enteros
- Estandarizar le da el mismo peso a holiday o windspeed: más ruido en la distancia
- Vecinos compartidos (crudo vs estandarizado): 7, 2 y 1 de 10

4.3 · ÁRBOL

Misma estructura y hojas, pero 6 de 1 729 predicciones cambian: el umbral cae justo en un valor y float32 lo mueve ~10^{-8}

4.4 · K-MEANS (K = 7, SILUETA)

Crudo: bloques de ~50 días (los separa day). Estandarizado: tipos de día (sábado, domingo, feriado, clima)

Bosque + su ficha de testigos, evaluado por días completos

QUÉ MODELO

Random forest

Menor error (27 bicis por hora) y cada predicción se explica con horas históricas concretas.

CUÁNDO NO CONFIAR

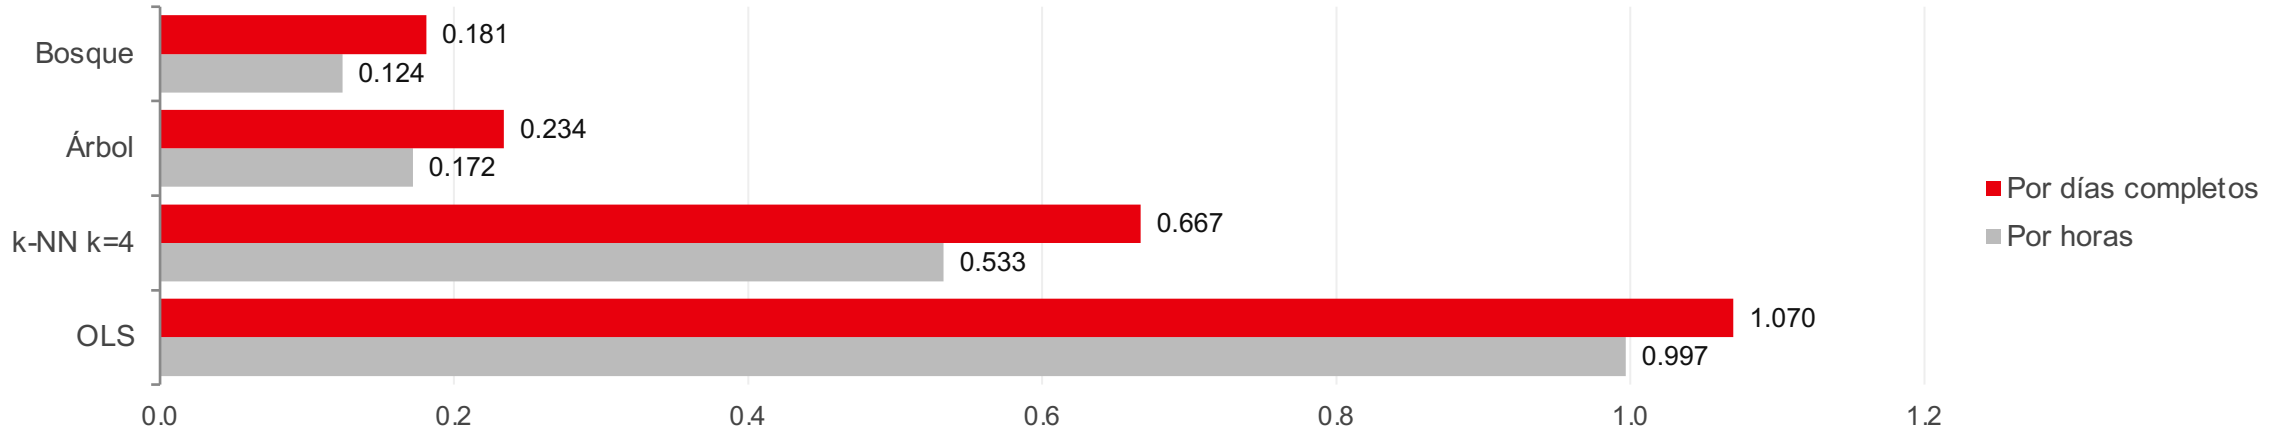
Testigos en desacuerdo

Error ×3. También: un solo testigo que no se parece, madrugadas, días atípicos.

QUÉ CAMBIA MÁS

La partición

Por días completos: el error del bosque sube ~45 % (sigue ganando). Luego: escala y flexibilidad.



Samuel L. Jackson: un grafo de colaboración es un kernel

$$B_{am} = \mathbf{1}\{\text{el actor } a \text{ sale en la película } m\}$$

$$A = BB^{\top} \quad \text{(fuera de la diagonal)}, \qquad A_{ab} = \sum_{m} B_{am} B_{bm}$$

$$(BB^{\top})_{aa} = \sum_{m} B_{am}^{2} = \#\,\text{películas que cuentan para } a$$

$$S = \frac{1}{T}\sum_{t=1}^{T} Z_t \,\mathrm{diag}\left(\frac{1}{|L|}\right) Z_t^{\top} \quad \longleftrightarrow \quad A = BB^{\top}$$

108

películas cuentan para Jackson (1975–2025, order < 5)

377

actores (nodos) y 2 666 aristas

$BB^{\top} = A$

fuera de la diagonal, exacto; B es 377 × 10 334

3

aislados (papeles de sí mismos): $\lambda_2 = 0$ con la semilla

Laplaciano: un valor propio cero por componente

01 Laplaciano: grado menos adyacencia (con pesos = películas compartidas)

$$L = D - A, \qquad D = \operatorname{diag}(d_1, \ldots, d_n), \qquad d_a = \sum_b A_{ab}$$

02 Laplaciano normalizado: cada arista se divide entre la raíz de los grados

$$L_{\text{sym}} = I - D^{-1/2} A D^{-1/2}$$

03 Forma cuadrática: vᵀLv = 0 obliga a v constante dentro de cada componente

$$v^{\mathsf{T}} L v = \frac{1}{2} \sum_{a,\,b} A_{ab} (v_a - v_b)^2 \;\geq\; 0$$

04 Por eso las componentes se cuentan con los valores propios (casi) cero

$$\#\,\text{componentes} = \#\{k : \; \lambda_k(L_{\text{sym}}) < 10^{-8}\}$$

05 Nodo aislado: D^(−1/2) no existe; con esta convención da λ = 0 y el conteo cuadra

$$d_a = 0 : \quad D_{aa}^{-1/2} := 0 \;\; \text{y} \;\; L_{\text{sym}} = D^{-1/2} L D^{-1/2} \;\Rightarrow\; \lambda = 0 \text{ para el aislado}$$

06 Mayor brecha. Con semilla: $\lambda_1 = \ldots = \lambda_4 = 0$ (3 aislados + resto); en su componente, $\lambda_2 = 0.247$

$$k^* = \arg\max_{1 \leq k \leq 14} \; (\lambda_{k+1} - \lambda_k)$$

Clustering espectral, Fiedler y centralidad

01 Ng–Jordan–Weiss. k = 3: Hollywood comercial (187), núcleo de Jackson de los 90 (115), cine afroamericano (72)

$$U = [v_1, \ \dots, v_k] \in \mathbb{R}^{n \times k}, \quad u_a \leftarrow \frac{u_a}{\|u_a\|}, \quad k-\text{means sobre las filas } u_a$$

02 Vector de Fiedler (sin la semilla): 318 actores del cine comercial contra 51 del afroamericano; cruza 15 % de las aristas

$$L_{\text{sym}} v_2 = \lambda_2 v_2, \qquad S^+ = \{a : \ v_{2a} \geq 0\}, \quad S^- = \{a : \ v_{2a} < 0\}$$

03 Centralidad de vector propio: 3 de 5 coinciden con el grado; entran Travolta y Freeman

$$A\,v = \lambda_{\max}\, v, \qquad c_a = \frac{|v_a|}{\max_b |v_b|}$$

Como el bosque con sus hojas: el espectro del kernel señala dónde la conexión (la evidencia) es débil.

PREGUNTAS

Gracias

Repositorio: notebook que corre de principio a fin, memo de la Parte 5, estas diapositivas y las partes individuales como submódulos.

Referencias
Sudjianto, The Learned Kernel (2026) · Hastie, Tibshirani y Friedman, ESL §7.4–7.6 · Fanaee-T y Gama (2014) · Pace y Barry (1997)

