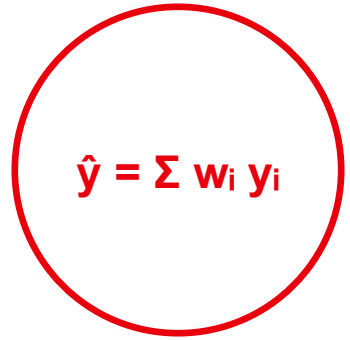
ANÁLISIS Y CIENCIA DE DATOS · PROYECTO FINAL

Todo modelo es un voto ponderado

Pesos, evidencia y geometría de cinco modelos sobre la demanda de bicicletas de Washington D.C. (2011)

Rodolfo Flores · Nohel Estrada · Humberto Najar
Facultad de Ingeniería, Universidad del Istmo de Guatemala
6 de noviembre de 2026



Una predicción es un voto de las filas de entrenamiento

$$\hat{y}(x) = \Sigma_i \, w_i(x) \cdot y_i$$

01

¿Quién vota?

Todas las filas (OLS, ridge), k vecinos, una hoja del árbol o la unión de hojas del bosque.

02

¿Cuánto vale cada voto?

1/k, 1/|hoja|, o un peso que depende de la geometría de X. El parecido entre filas es el kernel.

03

¿Hay votos en contra?

OLS y ridge dan pesos negativos; k-NN, árbol y bosque son promedios convexos ($w \geq 0$, $\Sigma w = 1$).

PLAN: PESOS → EVIDENCIA → COSTO DE LA FLEXIBILIDAD → ESCALA → VEREDICTO

Dos conjuntos de datos, una sola receta de preparación

PARTE 1 · CALIFORNIA HOUSING

- 20 640 distritos censales de 1990, 8 variables
- y = valor mediano de la vivienda (cientos de miles de USD)
- 16 512 entrenamiento · 4 128 prueba

PARTES 2–5 · BIKESHARE D.C.

- 8 645 horas de 2011; y = log(1 + bikers)
- day, hr, weekday, workingday, holiday, temp, hum, windspeed, mes 1–12, weathersit 1–4
- 6 916 entrenamiento · 1 729 prueba

100 %

de las filas cumplen casual + registered = bikers: usarlas sería usar la respuesta (fuga).

105

desviación cruda de day; hr ≈ 6.9, mes ≈ 3.4, windspeed ≈ 0.12. La usamos en la Parte 4.

80 / 20

partición con random_state = 0; el escalador se ajusta solo con entrenamiento.

Los pesos de cinco modelos, en una tabla

Modelo	Peso $w_i(x)$	¿Por qué suman 1?
OLS	$\tilde{x}^T (\tilde{X}^T\tilde{X})^{-1} \tilde{X}^T$	$H \cdot 1 = 1$: el vector de unos está en el espacio columna
Ridge ($\lambda = 100$)	$1/n + (x - \bar{x})^T (X_c^T X_c + \lambda I)^{-1} X_c^T$	$X_c^T 1 = 0$; el intercepto no se penaliza
k-NN ($k = 30$)	$1/k$ si x_i es vecino de x	k vecinos × 1/k
Árbol (prof. 6)	$1\{\text{misma hoja}\} / \lvert\text{hoja}\rvert$	promedio de la hoja
Bosque (200 árboles)	$(1/T)\ \Sigma_t\ 1\{\text{misma hoja en } t\} / \lvert\text{hoja}_t\rvert$	promedio de promedios

RIDGE "OBVIO": PENALIZAR TAMBIÉN LA COLUMNA DE UNOS

No cuadra con .predict() (diferencia de hasta 0.012) y los pesos suman **$n/(n+\lambda) = 0.994$**: el intercepto se encoge hacia 0.

Los cinco votos reproducen .predict() a 10^{-14}

Fila de prueba 7	Predicción	Σ w	Pesos ≠ 0	Pesos < 0
OLS	3.057	1.000	16 512	**4 144**
Ridge	3.056	1.000	16 512	**4 130**
k-NN	3.208	1.000	30	0
Árbol	3.699	1.000	328	0
Bosque	3.718	1.000	388	0

100 / 100

verificaciones: 20 filas de prueba × 5 modelos, $|\Sigma\, w_i y_i - \text{pred}| < 10^{-8}$

≈ 4 000

filas votan en contra en OLS y ridge: una de cada cuatro

Con bootstrap la fórmula falla; la proximidad no es un peso

0.044

error máximo de la fórmula con bootstrap = True (contra 10^{-15} sin bootstrap)

36.8 %

de las filas queda fuera de la bolsa de cada árbol; otras entran 2, 3… veces

6.495

suma de la proximidad de la fila 7 = tamaño medio de su hoja en los 200 árboles

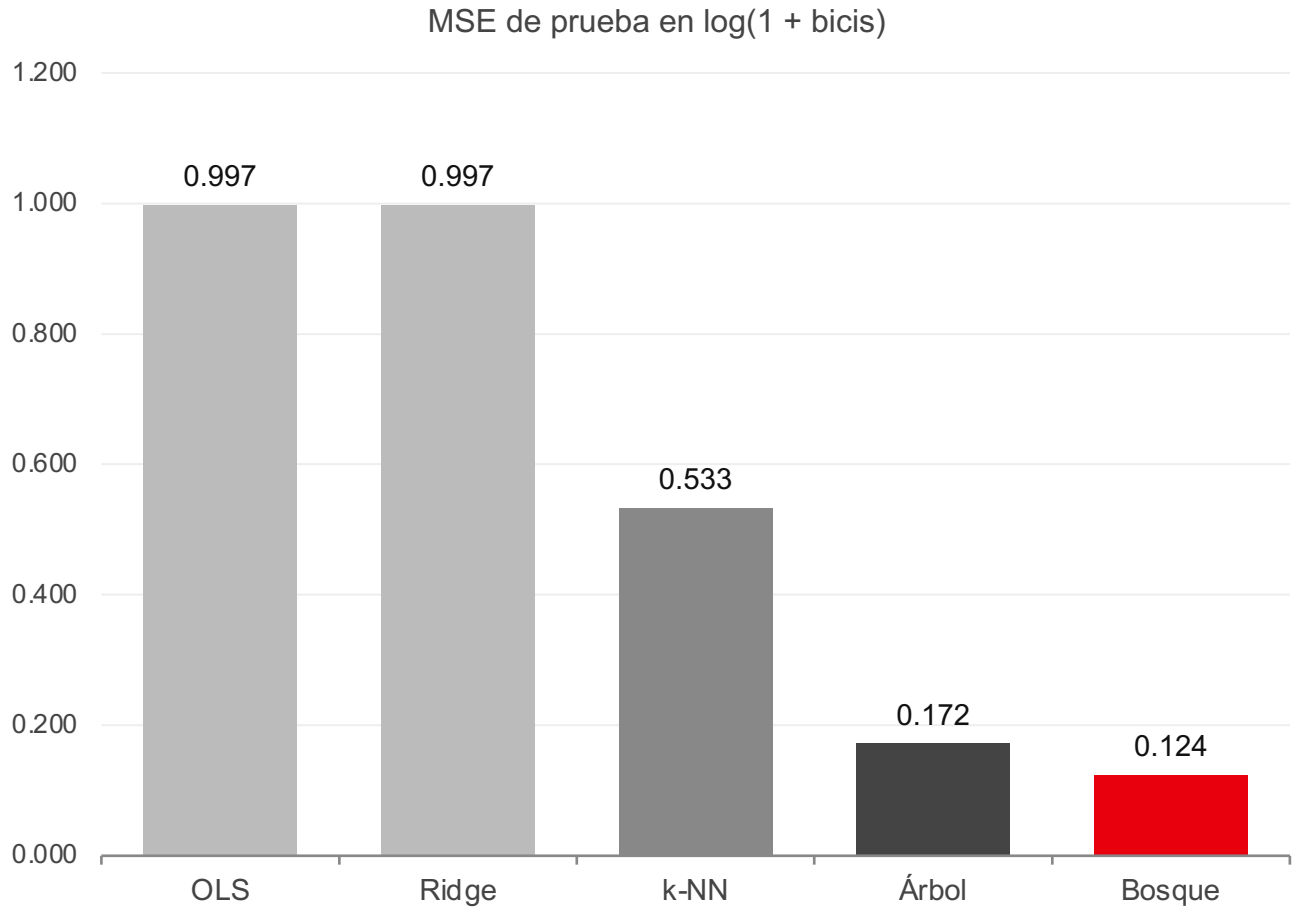
ARREGLO PARA BOOTSTRAP

- Contar cada fila tantas veces como entró a su árbol (c_{it}):
- $w_i(x) = (1/T)\ \Sigma_t\ c_{it}\ 1\{\text{misma hoja}\} / \Sigma_j\ c_{jt}\ 1\{\text{misma hoja}\}$
- Vuelve a reproducir .predict() a 10^{-15}

¿QUÉ LE FALTA A LA PROXIMIDAD?

- Cada coincidencia vale 1, sin importar el tamaño de la hoja
- Hay que dividir entre $|L_t(x)|$ dentro de cada árbol, antes de promediar
- Normalizarla al final no basta (difiere hasta 0.0026)

El bosque gana; los lineales no dibujan la hora punta



Modelo	Elegido por CV	MAE (bicis)
OLS	—	84.6
Ridge	$\lambda \approx 17.8$	84.5
k-NN	k = 4	53.1
Árbol	profundidad 11	27.4
Bosque	**min_samples_leaf = 1**	**27.2**

IMPORTANCIA EN EL BOSQUE

hr 0.65 · temp 0.09 · hum 0.07 · day 0.07

Tres consultas: una de ellas descansa en una sola fila

N_EF MEDIANO

Vie 7 oct · 11 h

Real	**230**
Predicción bosque	**187**
N_ef	**8.75**
c(x)	**0.42**

Testigo principal: 10 h de la misma semana (w = 0.22)

N_EF MÍNIMO

Sáb 29 oct · 18 h · nieve

Real	**43**
Predicción bosque	**32**
N_ef	**1.04**
c(x)	**0.9998**

Testigo principal: 17 h del mismo día (w = 0.98)

MAYOR ERROR

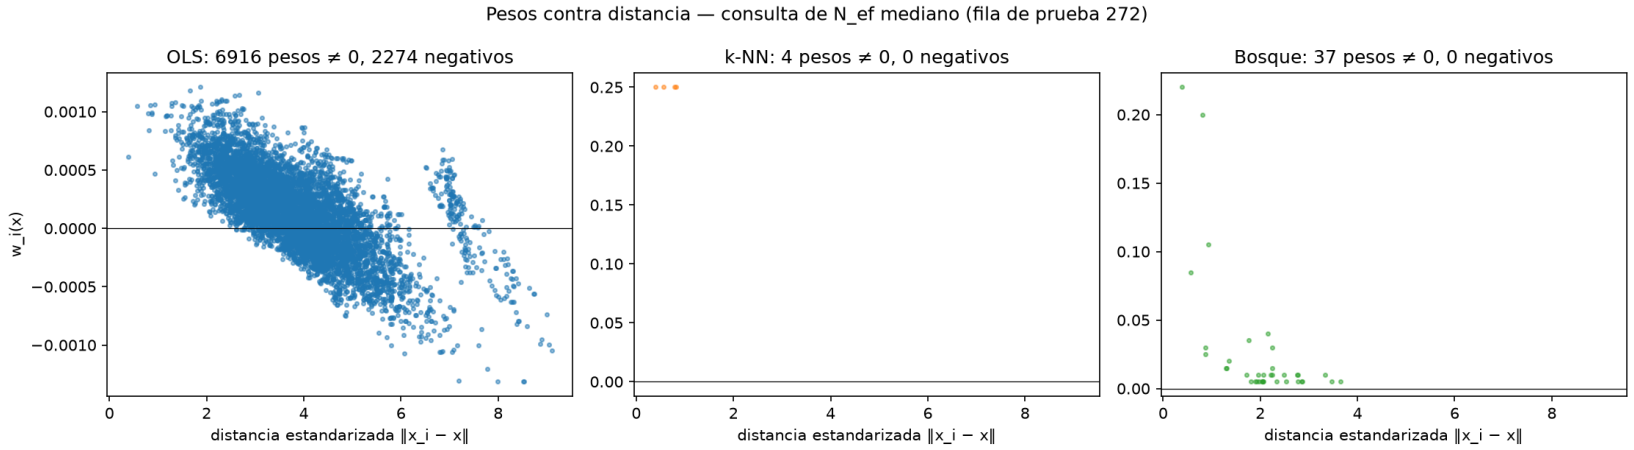
Mar 18 ene · 12 h

Real	**3**
Predicción bosque	**29**
N_ef	**2.26**
c(x)	**0.98**

Testigo principal: 13 h del mismo día (w = 0.66)

OLS/ridge: N_ef ≈ 1 000, pero sus testigos de mayor |w| son tardes lluviosas de verano con peso negativo.

OLS vota en contra con las filas más lejanas



2 274

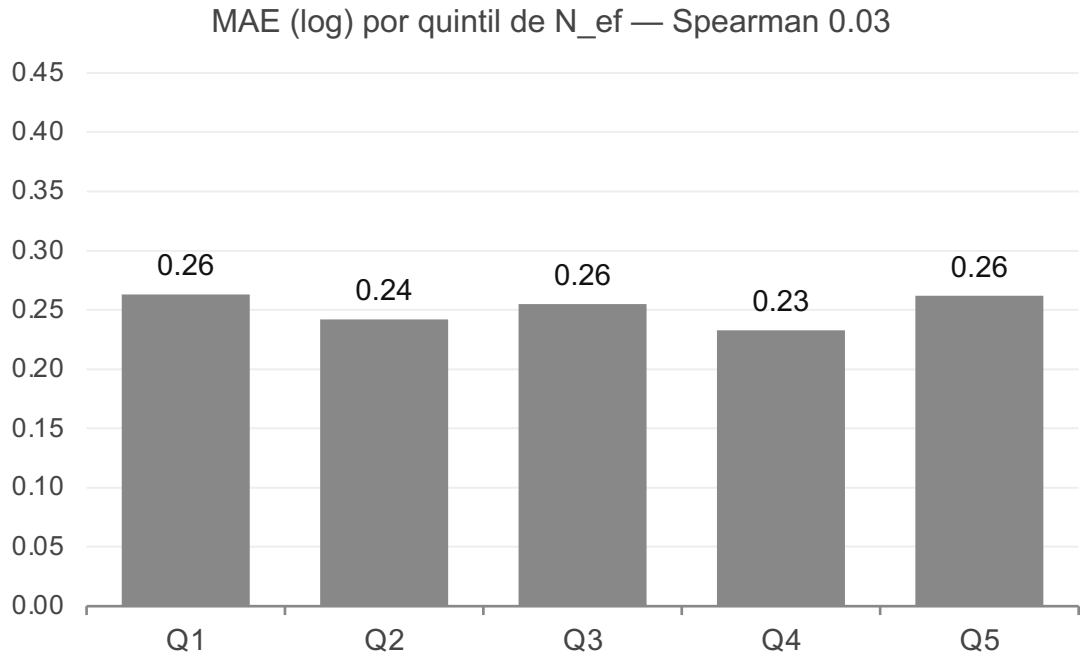
a 3 115 de los 6 916 pesos OLS son negativos, según la consulta

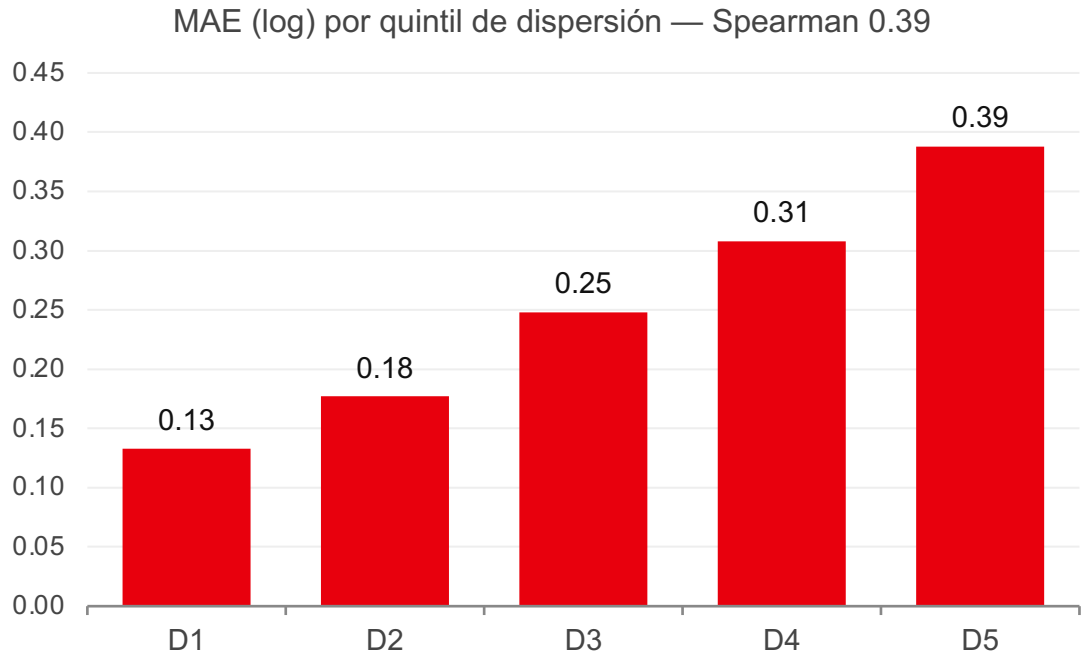
p96 – p99

percentil de distancia de las 5 filas con peso más negativo

- Cerca: pesos positivos. Lejos: negativos. Los de mayor magnitud están en los extremos de la nube.
- Como w(x) es lineal en x, OLS usa puntos de palanca (viento ≈ 0.85, lluvia) para inclinar el hiperplano y extrapolar.
- k-NN (4 pesos) y el bosque (37) solo dejan votar a vecinos cercanos, siempre con peso positivo.

N_ef no predice el error; la dispersión de testigos sí





Por qué: el bosque corta fino donde la señal cambia rápido (mediodía: N_ef ≈ 5, error bajo) y en log domina el ruido de madrugada (1–5 h: N_ef alto, error 0.33–0.48). Var ≈ $\sigma^2(x)/N_{ef}$: hace falta $\sigma^2(x)$.

Cuándo decirle a alguien que no confíe en una predicción

01

Los testigos discrepan

Dispersión ponderada alta: el error se triplica entre el quintil más bajo y el más alto.

02

Un solo testigo decide

$N_{ef} \lesssim 2$ o $c(x) > 0.9$, y ese testigo no se parece a la consulta (otra hora, otra estación).

03

OLS extrapola

Los testigos de mayor $|w|$ son filas lejanas con peso negativo: no es un promedio de casos parecidos.

04

Los modelos discrepan

El 18 de enero los cinco modelos van de 23 a 58 bicis: no hay casos parecidos cerca.

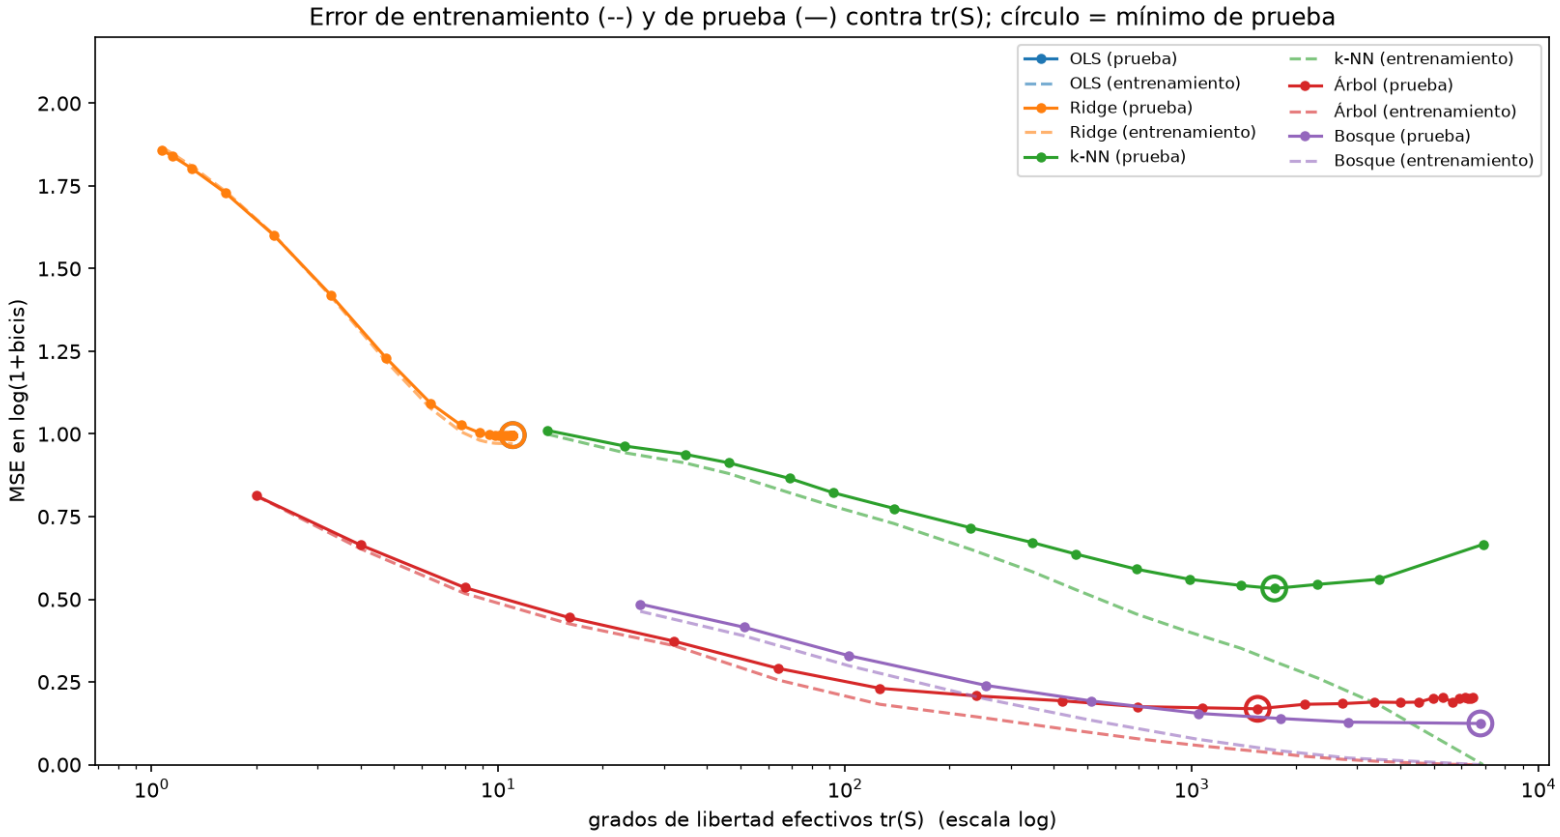
tr(S): cuánto se vota a sí misma cada fila

Modelo	Fórmula	Idea
OLS	$p + 1$	$\mathrm{tr}(\tilde{X}(\tilde{X}^T\tilde{X})^{-1}\tilde{X}^T) = \mathrm{tr}(I_{p+1})$
Ridge	$1 + \Sigma\, d_j^2/(d_j^2 + \lambda)$	SVD $X_c = UDV^T$
k-NN	n / k	$S_{ii} = 1/k$ (sin filas repetidas)
Árbol	nº de hojas	$\Sigma_L \Sigma_{\{i \in L\}} 1/\lvert L\rvert = \Sigma_L 1$
Bosque	$\Sigma\, S_{ii}$	sin forma cerrada

n = 2 000	Fórmula	np.trace(S)
OLS	11	11.000
Ridge λ = 17.8	10.197	10.197
k-NN k = 4	500	500.000
Árbol prof. 11	701	701.000
Bosque	1 967.56	1 967.56

MAX |S·Y − PRED| ≈ 10^{-15}

El bosque casi interpola y aun así generaliza mejor

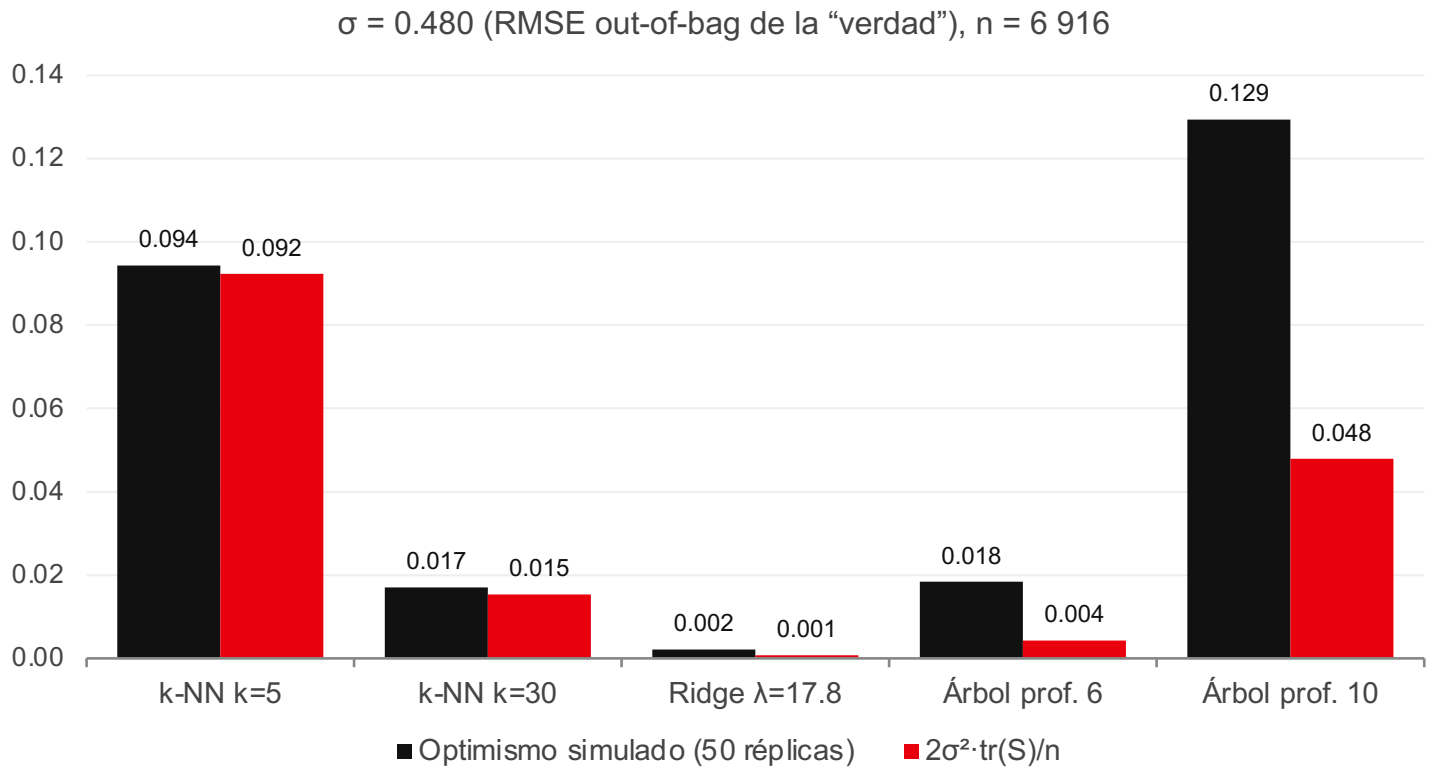


MÍNIMO DEL ERROR DE PRUEBA

Familia	Parámetro	MSE
OLS / Ridge	$\lambda \to 0$	0.997
k-NN	k = 4	0.533
Árbol	prof. 12	0.169
Bosque	**msl = 1**	**0.124**

tr(S) cuenta el voto de cada fila por sí misma; en un punto nuevo el bosque promedia 200 árboles distintos.

$2\sigma^2 \cdot tr(S)/n$ solo cuadra si S no depende de y



3.5: la brecha prueba − entrenamiento no es el optimismo, porque en prueba también cambian los x.

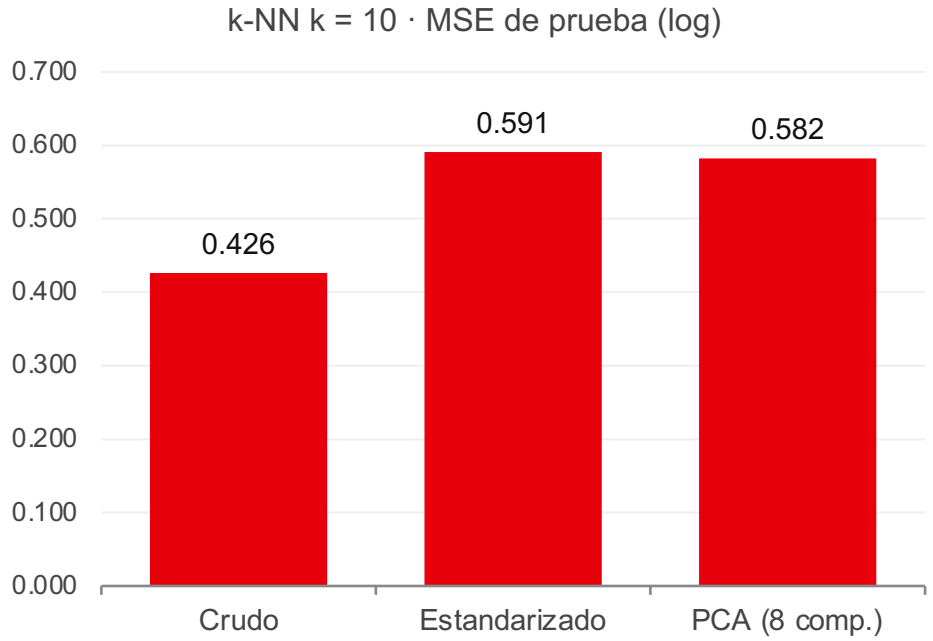
3.4 · POR QUÉ FALLA EN EL ÁRBOL

- k-NN y ridge: opt/fórmula = 1.02, 1.11 y ≈1 (dentro de 1.5 ee)
- Árbol: 4.3× y 2.7×. Los cortes se eligen mirando y, así que S depende de y

3.6 · OUT-OF-BAG

Error (MSE)	Valor
Entrenamiento	0.019
Out-of-bag	**0.141**
Prueba	0.136

En crudo, k-NN busca la misma hora en días vecinos



4.1 – 4.2 · K-NN

- day aporta 99.4 % de la varianza de la distancia cruda, pero day y hr están ambas en enteros
- Estandarizar le da el mismo peso a holiday o windspeed: más ruido en la distancia
- Vecinos compartidos (crudo vs estandarizado): 7, 2 y 1 de 10

4.3 · ÁRBOL

Misma estructura y hojas, pero 6 de 1 729 predicciones cambian: el umbral cae justo en un valor y float32 lo mueve ~10^{-8}

4.4 · K-MEANS (K = 7, SILUETA)

Crudo: bloques de ~50 días (los separa day). Estandarizado: tipos de día (sábado, domingo, feriado, clima)

Bosque + su ficha de testigos, evaluado por días completos

QUÉ MODELO

Random forest

Menor error (27 bicis por hora) y cada predicción se explica con horas históricas concretas.

CUÁNDO NO CONFIAR

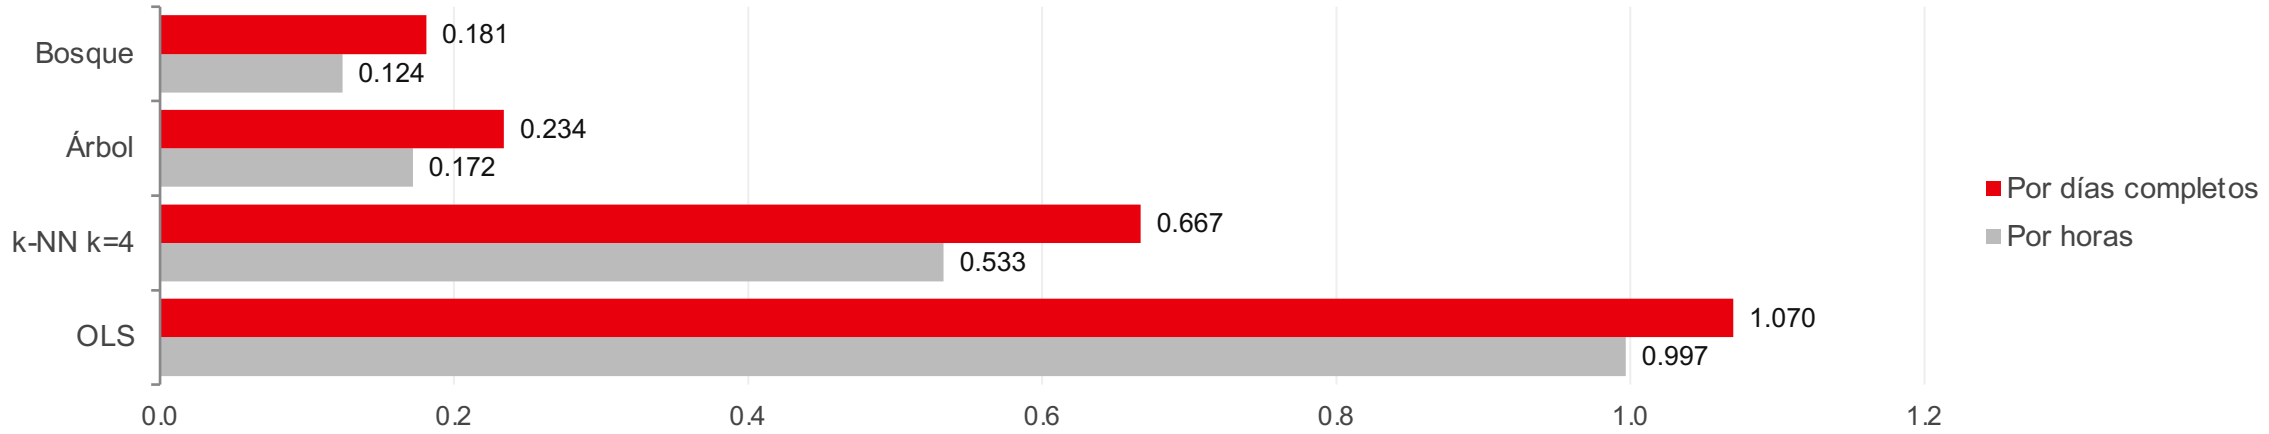
Testigos en desacuerdo

Error ×3. También: un solo testigo que no se parece, madrugadas, días atípicos.

QUÉ CAMBIA MÁS

La partición

Por días completos: el error del bosque sube ~45 % (sigue ganando). Luego: escala y flexibilidad.



PREGUNTAS

Gracias

Repositorio: notebook que corre de principio a fin, memo de la Parte 5, estas diapositivas y las partes individuales como submódulos.

Referencias
Sudjianto, The Learned Kernel (2026) · Hastie, Tibshirani y Friedman, ESL §7.4–7.6 · Fanaee-T y Gama (2014) · Pace y Barry (1997)

